Анализ Python-вакансий 2024

RustFS · потоковый MapReduce · DuckDB

В файле содержится 10 205 102 записи вакансий и строка заголовка. Исходный CSV размером 24 970 431 974 байта не изменялся; gzip-объект в RustFS подтверждён полным чтением и SHA-256.

Вариант и правило выборки

Вариант: Python. В сегмент включена строка, если название name содержит python без учёта регистра либо отдельный токен python присутствует в списке key_skills, разделённом точкой с запятой. Описание вакансии не анализировалось. Навыки нормализованы в нижний регистр, повторы внутри строки удалены; пары и тройки — неупорядоченные сочетания.

Результаты обработки

Показатель	Результат
Строк CSV	10 205 102
Python-сегмент	20 033
Уникальные навыки / пары / тройки	6 644 / 136 352 / 1 080 737
Всего упоминаний навыков / пар / троек	153 910 / 827 832 / 3 930 552
Аудит MapReduce ↔ DuckDB	не выполнен

Наиболее частые навыки

Одиночные навыки

Комбинация	Вакансий
python	18 358
sql	7 137
linux	4 471
postgresql	3 545
git	3 117
docker	2 668
bash	1 888
java	1 438
javascript	1 423
kubernetes	1 363

Пары

Комбинация	Вакансий
python + sql	7 110
linux + python	4 440
postgresql + python	3 500
git + python	3 076
docker + python	2 622
bash + python	1 887
java + python	1 436
javascript + python	1 410

Комбинация	Вакансий
bash + linux	1 409
git + linux	1 394

Тройки

Комбинация	Вакансий
bash + linux + python	1 409
git + linux + python	1 381
postgresql + python + sql	1 329
docker + linux + python	1 236
git + python + sql	1 108
linux + postgresql + python	1 093
git + postgresql + python	1 080
linux + python + sql	1 069
docker + postgresql + python	1 001
python + sql + анализ данных	997

Рост числа сочетаний

В сегменте: 153,910 одиночных упоминаний, 827,832 парных и 3,930,552 тройных сочетаний. Вакансия с k уникальными навыками даёт k, C(k,2) и C(k,3) комбинаций; распределение числа навыков: 0 навыков — 1 451, 1 навыков — 206, 2 навыков — 666, 3 навыков — 1 370, 4 навыков — 2 068, 5 навыков — 2 407, 6 навыков — 1 916, 7 навыков — 1 742, 8 навыков — 1 417, 9 навыков — 1 311, 10 навыков — 942, 11 навыков — 800, 12 навыков — 637, 13 навыков — 596, 14 навыков — 498, 15 навыков — 337, 16 навыков — 262, 17 навыков — 206, 18 навыков — 202, 19 навыков — 129, 20 навыков — 169, 21 навыков — 88, 22 навыков — 51, 23 навыков — 46, 24 навыков — 64, 25 навыков — 56, 26 навыков — 61, 27 навыков — 40, 28 навыков — 27, 29 навыков — 96, 30 навыков — 172. Среднее k=7.68.

Региональный срез: три лидирующих региона

Регион/area	Вакансий	Зарплат с RUR	Медиана, ₽
Москва	10113	2405	176 250
Санкт-Петербург	2544	803	130 000
Екатеринбург	694	254	100 000

Москва: востребованные навыки

Навыки/сочетания	Вакансий
python	9341
sql	3986
linux	2159
postgresql	1879
docker	1460
python + sql	3971
linux + python	2141
postgresql + python	1851
docker + python	1425

Навыки/сочетания	Вакансий
git + python	1386
postgresql + python + sql	723
bash + linux + python	697
docker + linux + python	669
git + linux + python	643
python + sql + анализ данных	575

Санкт-Петербург: востребованные навыки

Навыки/сочетания	Вакансий
python	2350
sql	826
linux	644
postgresql	417
git	405
python + sql	823
linux + python	640
postgresql + python	414
git + python	400
docker + python	358
bash + linux + python	226
git + linux + python	189
docker + linux + python	180
git + postgresql + python	143
postgresql + python + sql	140

Екатеринбург: востребованные навыки

Навыки/сочетания	Вакансий
python	642
sql	219
linux	178
postgresql	141
git	137
python + sql	218
linux + python	176
postgresql + python	139
git + python	133
docker + python	105
git + linux + python	57
bash + linux + python	57
docker + linux + python	53
git + postgresql + python	49

Навыки/сочетания	Вакансий
postgresql + python + sql	46

Зарплатный эффект навыковых сочетаний

Только валюта RUR; диапазон зарплаты заменён серединой границ, для одностороннего диапазона используется заданная граница. В выборку сочетаний вошли пары/тройки с минимум 30 вакансиями и 20 известными зарплатами. База — медиана наиболее часто встречающегося одиночного навыка из сочетания в Python-сегменте; Δ = (медиана сочетания / медиана базы − 1) × 100%. Это описательная, не причинная оценка.

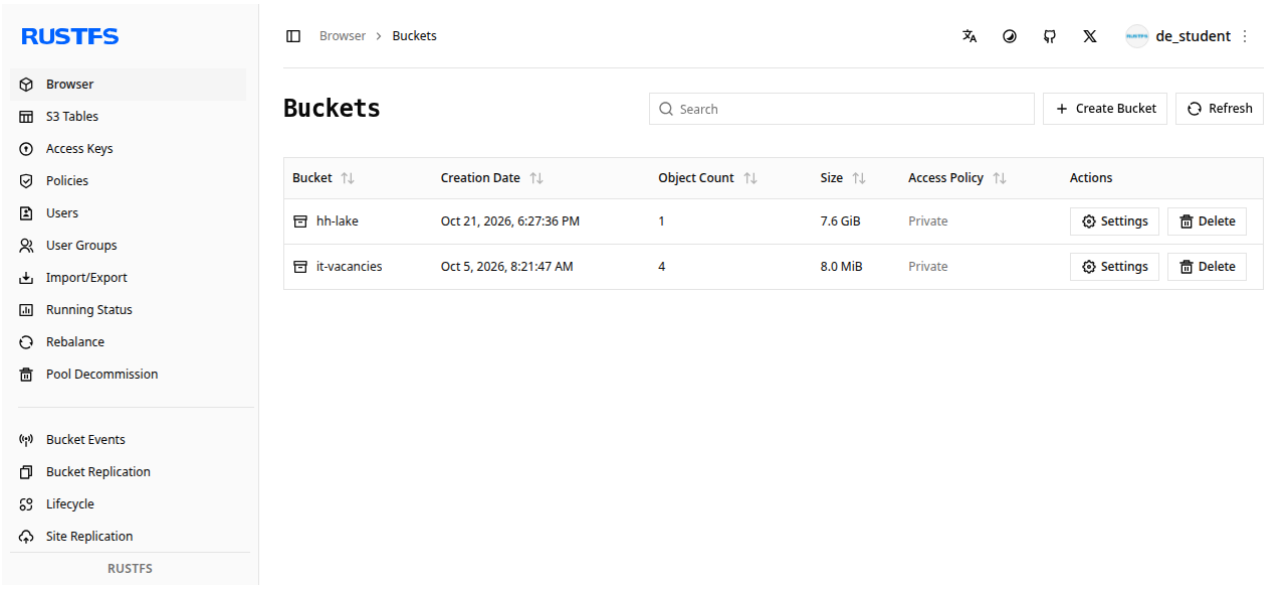
Производительность и контроль

Строк в блоке	Время, с	Пиковая RSS, MiB
1000	343.8	610.9
10000	359.1	681.7
100000	351.3	1534.3

Тест отказа mapper: искусственная ошибка должна завершать задачу с ошибкой; частичный результат не публикуется. MapReduce и SQL используют один S3 gzip-объект и единый сегмент; аудит сверяет словари одиночных навыков, пар и троек и число вакансий. В качестве оптимизации локальные счётчики блока редуцируются агрегированно, уменьшая количество операций записи в итоговые глобальные счётчики.

Ограничения: RustFS использует восемь каталогов на одном физическом NVMe (учебная конфигурация, без отказоустойчивости к потере диска). Зарплата указана только при валюте RUR, пропуски не импутируются. CSV является снимком 2024 года.

Скриншот консоли RustFS: rustfs buckets



Скриншот консоли RustFS: rustfs hh lake object

