Анализ Python-вакансий 2024

RustFS · потоковый MapReduce · DuckDB

В файле содержится 10 205 102 записи вакансий и строка заголовка. Исходный CSV размером 24 970 431 974 байта не изменялся; gzip-объект в RustFS подтверждён полным чтением и SHA-256.

Объект: s3://hh-lake/vacancies_2024.csv.gz · 8 107 206 336 байт · SHA-256 490b213766869b28648e35bffbcc037a75671077e7922c56aab895d49f3d9ed8 · исходный CSV SHA-256 4f8dcf7c3ba8dab89df4f26639424ab89e5f59fd58a44cd5da0b07f80dac6d80.

Вариант и правило выборки

Вариант: Python. В учебном чате более точный предикат отбора не задан, поэтому для воспроизводимости используется явное правило: строка включается, если название name содержит python без учёта регистра либо отдельный токен python присутствует в списке key_skills, разделённом точкой с запятой. Описание вакансии не анализировалось. Навыки нормализованы в нижний регистр, повторы внутри строки удалены; пары и тройки — неупорядоченные сочетания.

Результаты обработки

Показатель	Результат
Строк CSV	10 205 102
Python-сегмент	20 033
Уникальные навыки / пары / тройки	6 644 / 136 352 / 1 080 737
Всего упоминаний навыков / пар / троек	153 910 / 827 832 / 3 930 552
Аудит MapReduce ↔ DuckDB	PASS

Наиболее частые навыки

Одиночные навыки

Комбинация	Вакансий
python	18 358
sql	7 137
linux	4 471
postgresql	3 545
git	3 117
docker	2 668
bash	1 888
java	1 438
javascript	1 423
kubernetes	1 363

Пары

Комбинация	Вакансий
python + sql	7 110
linux + python	4 440
postgresql + python	3 500
git + python	3 076

Комбинация	Вакансий
docker + python	2 622
bash + python	1 887
java + python	1 436
javascript + python	1 410
bash + linux	1 409
git + linux	1 394

Тройки

Комбинация	Вакансий
bash + linux + python	1 409
git + linux + python	1 381
postgresql + python + sql	1 329
docker + linux + python	1 236
git + python + sql	1 108
linux + postgresql + python	1 093
git + postgresql + python	1 080
linux + python + sql	1 069
docker + postgresql + python	1 001
python + sql + анализ данных	997

Рост числа сочетаний

В сегменте: 153,910 одиночных упоминаний, 827,832 парных и 3,930,552 тройных сочетаний. Вакансия с k уникальными навыками даёт k, C(k,2) и C(k,3) комбинаций; распределение числа навыков: 0 навыков — 1 451, 1 навыков — 206, 2 навыков — 666, 3 навыков — 1 370, 4 навыков — 2 068, 5 навыков — 2 407, 6 навыков — 1 916, 7 навыков — 1 742, 8 навыков — 1 417, 9 навыков — 1 311, 10 навыков — 942, 11 навыков — 800, 12 навыков — 637, 13 навыков — 596, 14 навыков — 498, 15 навыков — 337, 16 навыков — 262, 17 навыков — 206, 18 навыков — 202, 19 навыков — 129, 20 навыков — 169, 21 навыков — 88, 22 навыков — 51, 23 навыков — 46, 24 навыков — 64, 25 навыков — 56, 26 навыков — 61, 27 навыков — 40, 28 навыков — 27, 29 навыков — 96, 30 навыков — 172. Среднее k=7.68.

Региональный срез: три лидирующих региона

Регион/area	Вакансий	Зарплат с RUR	Медиана, ₽
Москва	10113	2405	176 250
Санкт-Петербург	2544	803	130 000
Екатеринбург	694	254	100 000

Наблюдение: медиана Москвы выше Санкт-Петербурга на 35.6% и Екатеринбурга на 76.2%. Доля объявлений с указанной зарплатой различается (Москва: 23.8% / Санкт-Петербург: 31.6% / Екатеринбург: 36.6%), поэтому медианы описывают подвыборки с разным покрытием.

Москва: востребованные навыки

Навыки/сочетания	Вакансий
python	9341
sql	3986
linux	2159

Навыки/сочетания	Вакансий
postgresql	1879
docker	1460
python + sql	3971
linux + python	2141
postgresql + python	1851
docker + python	1425
git + python	1386
postgresql + python + sql	723
bash + linux + python	697
docker + linux + python	669
git + linux + python	643
python + sql + анализ данных	575

Санкт-Петербург: востребованные навыки

Навыки/сочетания	Вакансий
python	2350
sql	826
linux	644
postgresql	417
git	405
python + sql	823
linux + python	640
postgresql + python	414
git + python	400
docker + python	358
bash + linux + python	226
git + linux + python	189
docker + linux + python	180
git + postgresql + python	143
postgresql + python + sql	140

Екатеринбург: востребованные навыки

Навыки/сочетания	Вакансий
python	642
sql	219
linux	178
postgresql	141
git	137
python + sql	218
linux + python	176
postgresql + python	139

Навыки/сочетания	Вакансий
git + python	133
docker + python	105
bash + linux + python	57
git + linux + python	57
docker + linux + python	53
git + postgresql + python	49
postgresql + python + sql	46

Зарплатный эффект навыковых сочетаний

Только валюта RUR; диапазон зарплаты заменён серединой границ, для одностороннего диапазона используется заданная граница. В выборку сочетаний вошли пары/тройки с минимум 30 вакансиями и 20 известными зарплатами. База — медиана наиболее часто встречающегося одиночного навыка из сочетания в Python-сегменте; Δ = (медиана сочетания / медиана базы − 1) × 100%. Это описательная, не причинная оценка.

Наибольший рост медианы

Сочетание	N	Медиана ₽	База навыка	Δ
golang + javascript	45	337 500	javascript	+321.9%
.net framework + c#	49	225 000	c#	+309.1%
mathcad + python	36	402 500	python	+235.4%
big data + pandas	40	343 750	big data	+219.8%
asyncio + python + redis	42	375 000	python	+212.5%
python + teamleading	73	357 500	python	+197.9%
asyncio + postgresql + python	76	350 000	python	+191.7%
python + руководство командой разработчиков	49	350 000	python	+191.7%
aiohttp + asyncio + python	39	350 000	python	+191.7%
asyncio + python	154	345 000	python	+187.5%

Наибольшее снижение медианы

Сочетание	N	Медиана ₽	База навыка	Δ
css + mysql + sql	42	35 000	sql	-73.6%
adobe photoshop + sql	34	35 000	sql	-73.6%
android + java + sql	33	35 000	sql	-73.6%
sql + грамотность	30	35 000	sql	-73.6%
javascript + sql + unity	35	37 500	sql	-71.8%
gimp + python	76	35 000	python	-70.8%
gimp + python + робототехника	58	35 000	python	-70.8%
gimp + python + unity	58	35 000	python	-70.8%
adobe photoshop + python + робототехника	52	35 000	python	-70.8%
c++ + gimp + python	50	35 000	python	-70.8%

Производительность и контроль

Строк в блоке	Время, с	Пиковая RSS, MiB
1000	225.0	611.2
10000	230.7	682.4
100000	236.7	1528.3

DuckDB: 93.8 с, пиковая RSS 4303.3 MiB.

Сравнение на одной машине: SQL завершился в 2.46 раза быстрее MapReduce с блоком 10 000 строк; пиковая RSS DuckDB выше (ограничение DuckDB — 4 GiB, два потока). Это сравнение конкретных реализаций и конфигураций, а не универсальное преимущество движка.

Интерпретация эффекта: `asyncio + python` — медиана 345,000 ₽ против 120,000 ₽ у более частого базового навыка python (+187.5%, 60 зарплатных наблюдений). Для `gimp + python` медиана 35,000 ₽ против 120,000 ₽ у python (-70.8%, 61 наблюдений). Снижение, вероятно, отражает иной состав ролей и зарплатных объявлений, а не причинное влияние навыка.

Сводка результатов запусков (по сохранённым JSON; полный stdout не сохранялся)

Запуск	Краткая сводка сохранённого результата
mr --chunk-rows 1000	rows=10205102; python=20033; t=225.014s; peak=611.2MiB
mr --chunk-rows 10000	rows=10205102; python=20033; t=230.711s; peak=682.4MiB
mr --chunk-rows 100000	rows=10205102; python=20033; t=236.656s; peak=1528.3MiB
duckdb	python=20033; t=93.824s; peak=4303.3MiB; unique=6644/136352/1080737
audit	PASS; 3/3 чанка совпали, mismatch=0 для уровней 1/2/3
fail-test	PASS; injected error; partial result published=false
benchmark_filter	1,000,000 строк; +23.37% времени; выбранные строки равны

Бонус: до/после оптимизации предварительного фильтра

Метод	Медиана 5 запусков, с	Пик временных аллокаций, байт
До: нормализация set/sort навыков	1.2579	11166
После: ранний title + прямой токен	1.0196	6356
Ускорение	+23.4%	выборки совпали

Микробенчмарк выполнен на первых 1 000 000 строках того же S3-объекта по 5 повтора для каждого варианта. Метрика пика — временные Python-аллокации замеренные tracemalloc; полная пиковая RSS для обработки датасета приведена отдельно выше.

Пиковые временные аллокации уменьшились на 43.1% (11166 → 6356 байт). Это измерение относится к фильтру поверх уже загруженного набора строк и не выдаётся за снижение RSS полного процесса.

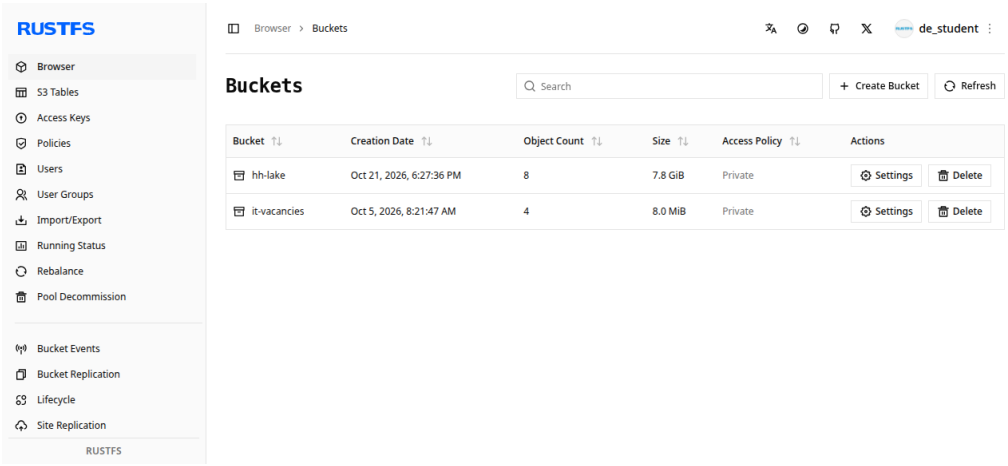
Тест отказа mapper: искусственная ошибка должна завершать задачу с ошибкой; частичный результат не публикуется. MapReduce и SQL используют один S3 gzip-объект и единый сегмент; аудит сверяет словари одиночных навыков, пар и троек и число вакансий. В качестве оптимизации локальные счётчики блока редуцируются агрегированно, уменьшая количество операций записи в итоговые глобальные счётчики.

Read-back проверка RustFS: PASS для 8 объектов — исходного gzip и семи файлов результатов. SHA-256 каждого объекта, прочитанного из S3, совпал с контрольным файлом/хешем источника; полный манифест опубликован в `results/s3_integrity_manifest.json`.

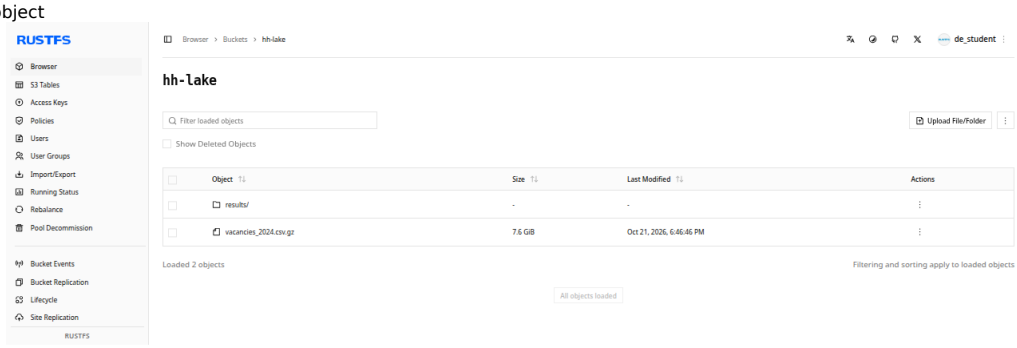
Ограничения: RustFS использует восемь каталогов на одном физическом NVMe (учебная конфигурация, без отказоустойчивости к потере диска). Зарплата указана только при валюте RUR, пропуски не импутируются. CSV является снимком 2024 года.

Приложение. Проверка RustFS и объектов в hh-lake

rustfs buckets



rustfs hh lake object



rustfs results objects

