Анализ Python-вакансий 2024

RustFS · потоковый MapReduce · DuckDB

В файле содержится 10 205 102 записи вакансий и строка заголовка. Исходный CSV размером 24 970 431 974 байта не изменялся; gzip-объект в RustFS подтверждён полным чтением и SHA-256.

Вариант и правило выборки

Вариант: Python. В сегмент включена строка, если название name содержит python без учёта регистра либо отдельный токен python присутствует в списке key_skills, разделённом точкой с запятой. Описание вакансии не анализировалось. Навыки нормализованы в нижний регистр, повторы внутри строки удалены; пары и тройки — неупорядоченные сочетания.

Результаты обработки

Статус на момент сборки: подтверждена загрузка и целостность исходного набора, опубликован воспроизводимый код MapReduce и DuckDB, выполнены два unit-теста и тест искусственного отказа mapper. Полный аналитический проход по 10,2 млн строк и сверка двух движков ещё выполняются; численные аналитические выводы здесь намеренно не приводятся.

Проверка объекта

s3://hh-lake/vacancies_2024.csv.gz · 8 107 206 336 байт · SHA-256 490b213766869b28648e35bffbcc037a75671077e7922c56aab895d49f3d9ed8 · проверен потоковым чтением целиком.

Сегмент и алгоритм

Вариант Python: name содержит Python без учёта регистра либо отдельный токен Python присутствует в key_skills. Описание не анализируется. Mapper считает уникальные навыки строки и их неупорядоченные пары и тройки; reducer объединяет локальные счётчики блоков. Команда полного запуска и независимого SQL-аудита приведена в README репозитория.